



DOCUMENTO DE ESTUDO • ARQUITETURA INICIAL

Assistente Hurtz Agente de voz para atendimento

Intenção, objetivo, funcionamento, tecnologias, limitações, custos inevitáveis e caminho de implementação.

Ecosistema CBO / Hurtz

Versão de estudo 1.0 • 26 de julho de 2026

Intenção do projeto

O Assistente Hurtz será uma inteligência artificial capaz de atender chamadas com voz natural, compreender o que a pessoa diz, consultar informações da empresa, responder com contexto e conduzir o atendimento até uma solução ou transferência para um humano.

A intenção não é criar apenas um robô que lê frases prontas. O produto deve manter uma conversa coerente, respeitar regras, ouvir interrupções, lembrar o que já foi dito e tomar ações seguras.

Objetivo principal

Automatizar atendimentos de voz repetitivos sem perder clareza, naturalidade e controle. A IA deve diminuir tempo de espera e carga operacional, mas reconhecer imediatamente quando não possui segurança para continuar.

1 Ouvir

Receber áudio contínuo e detectar voz, silêncio, interrupções e fim de turno.

2 Entender

Transcrever em português e interpretar intenção, dúvidas, objeções e urgência.

3 Responder

Construir uma resposta curta com base no contexto e nas regras da empresa.

4 Falar e agir

Gerar voz natural, registrar informações e transferir quando necessário.

Posição dentro do ecossistema

O Hurtz Launcher passará a organizar dois produtos independentes:

Ferramenta	Papel
Assistente de Reunião	Apoia uma pessoa durante reuniões, transcreve, consulta documentos, sugere falas, cria notas e próximos passos.
Assistente Hurtz	Conversa diretamente com clientes em uma chamada, usando sua própria voz artificial e tomando ações controladas.

Como uma chamada deve funcionar

1. A pessoa liga ou abre um link de atendimento.
2. O Hurtz atende, identifica-se e apresenta a informação de consentimento aplicável.
3. O áudio da pessoa chega ao motor de voz em pequenos blocos.
4. O sistema detecta quando ela começou e terminou de falar.
5. A transcrição parcial ajuda a IA a preparar a resposta antecipadamente.
6. Documentos e dados relevantes são consultados.
7. A IA começa a responder com voz natural.
8. Se a pessoa interromper, a voz da IA para imediatamente e volta a ouvir.
9. A conversa continua preservando histórico, objetivo e dados coletados.
10. Ao final, o Hurtz registra resumo, resultado e próximos passos.

CLIENTE FALA

↓ áudio em tempo real

Detecção de voz e turno

↓

Transcrição incremental

↓

Contexto + documentos + regras

↓

Modelo de inteligência

↓ texto em pequenos blocos

Voz natural

↓

CLIENTE OUVI A RESPOSTA

Metas de usabilidade

Comportamento	Meta inicial
Primeira reação após a fala	Começar a responder idealmente em 1 a 2 segundos.
Interrupção	Parar a voz da IA quase imediatamente quando o cliente falar.
Naturalidade	Frases curtas, sem repetir instruções ou produzir textos longos.
Memória	Não perguntar novamente dados que já foram informados.
Segurança	Não inventar preço, condição, prazo ou política.

As peças do sistema

Camada	Função	Escolha inicial
Canal de chamada	Recebe e devolve o áudio.	WebRTC no MVP; SIP ou WhatsApp depois.
Orquestração	Conecta todos os componentes e controla turnos.	Pipecat.
VAD/turno	Detecta fala, silêncio e interrupções.	Pipeline em tempo real do Pipecat.
STT	Transforma fala em texto.	Faster-Whisper adaptado para streaming.
RAG/contexto	Localiza informações em documentos.	Base local Hurtz, separada por empresa.
LLM	Decide o conteúdo da resposta.	Ollama com Qwen3 8B; fallback menor.
TTS	Transforma texto em voz.	Gemini 3.1 Flash TTS Preview.
Ações	Agenda, registra, transfere e envia mensagens.	Ferramentas controladas + Evolution API.
Observabilidade	Mede falhas, qualidade e tempo de resposta.	Logs e métricas na VPS.

Pipecat não é a inteligência. Ele é o maestro do sistema: recebe áudio, chama transcrição, contexto, modelo e voz na ordem correta, além de controlar interrupções.

Separação necessária

Base de conhecimento
Documentos oficiais, produtos, preços, políticas e perguntas frequentes. Atualizada administrativamente.

Memória da chamada
O que aquele cliente disse, dados coletados, decisões e estado atual. Expira ou é armazenada conforme a política.

Regras do agente
Tom, limites, objetivos, condições de transferência e ações permitidas.

Dados operacionais
Cliente, CRM, agenda, protocolos, resultado, duração e gravação autorizada.

Evolution API e chamadas de voz

A Evolution API é excelente para mensagens do WhatsApp, mas não deve ser confundida com um transporte completo de áudio de chamadas.

O que ela faz bem

- Conectar uma instância do WhatsApp e trocar mensagens.
- Receber e enviar áudios gravados, imagens e documentos.
- Disparar webhooks e integrar CRM, Chatwoot ou n8n.
- Identificar eventos relacionados a chamadas e, conforme a configuração, rejeitá-las.
- Enviar confirmação, protocolo e resumo depois de um atendimento.

O que não está disponível nela sozinha

- Um fluxo documentado de áudio bidirecional da chamada chegando ao nosso Pipecat.
- Uma conexão SIP nativa completa para o agente ouvir e responder.
- Garantia de estabilidade de chamadas quando a conexão usa WhatsApp Web/Baileys.

WhatsApp

├─ Mensagens → Evolution API → Hurtz
└─ Chamada → camada de voz/SIP → Hurtz

Evolution API sozinha ≠ áudio completo da ligação

Onde entra o Wavoip

O projeto da Evolution possui referências a wavoipToken. O Wavoip é uma camada separada que anuncia chamadas de WhatsApp e integração SIP. A arquitetura possível seria:

WhatsApp → Evolution/Wavoip → SIP → Pipecat → IA Hurtz

Decisão recomendada: validar essa rota com um número secundário. Não usar inicialmente o número principal da empresa, pois modos não oficiais podem sofrer desconexões, mudanças de protocolo ou restrições da plataforma.

Fontes para estudo: github.com/evolution-foundation/evolution-api • wavoip.com • github.com/WhiskeySockets/Baileys

Três caminhos para colocar o agente no ar

Caminho	Vantagens	Limitações
WebRTC por link MVP recomendado	Software gratuito, áudio sob nosso controle, implementação segura e teste rápido.	A pessoa precisa abrir um link; não é uma ligação para número comum.
Telefonia SIP Produção	Liga e recebe de celulares e fixos; transferência e filas profissionais.	Número e minutos são cobrados por uma operadora.
Chamada WhatsApp Experimento	Familiar ao cliente e usa um canal popular.	Exige camada adicional, precisa ser validada e pode ter risco quando não oficial.

Por que começar com WebRTC

O WebRTC permite testar a parte realmente difícil — interrupção, transcrição, raciocínio, documentos e voz — sem contratar telefonia. O Asterisk é um PABX gratuito que pode aceitar WebRTC e, mais tarde, conectar o mesmo sistema a um tronco SIP.

FASE 1 – GRATUITA

Link de atendimento → WebRTC → Hurtz

FASE 2 – TELEFONIA

Número real → Tronco SIP → Asterisk → Hurtz

FASE 3 – WHATSAPP

Chamada WhatsApp → camada validada de voz/SIP → Hurtz

Não existe telefonia externa ilimitada realmente gratuita. A central, a IA e o software podem ser nossos; a operadora que conecta celulares e fixos cobra número ou minutos.

Fonte para estudo: docs.asterisk.org/Configuration/WebRTC/

Como o Hurtz entende e responde

Transcrição — Faster-Whisper

Podemos reaproveitar o conhecimento adquirido no Assistente de Reunião, mas a implementação precisa ser adaptada. Em chamadas, esperar uma frase longa terminar gera atraso. O sistema deverá processar blocos pequenos, manter palavras parciais e confirmar o turno rapidamente.

REQUISITOS

- Vocabulário personalizado: nomes de produtos, marcas e termos comerciais.
- Cancelamento de segmentos antigos e consolidação sem palavras quebradas.
- Detecção de ruído e silêncio.
- Medição de tempo até a primeira transcrição útil.

Modelo — Ollama

O computador possui RTX 4060 Ti com 8 GB de VRAM e 32 GB de RAM. O candidato inicial é o **Qwen3 8B**, com resposta em modo direto, sem raciocínio longo. O atual Llama 3.2 3B pode servir de contingência rápida.

Princípio: em voz, o melhor modelo não é o maior. É o modelo que produz uma primeira frase correta rapidamente e mantém coerência ao longo da chamada.

Voz — Google Gemini TTS

O Gemini TTS oferece português e controle de estilo, ritmo e entonação. O candidato é o **Gemini 3.1 Flash TTS Preview**, atualmente documentado com streaming.

- Precisar de chave da API.
- Pode possuir franquia gratuita, limites e cobrança conforme uso.
- Por estar em Preview, precisa de repetição automática e fornecedor alternativo.
- O texto deve ser enviado em fragmentos naturais, sem cortar palavras.

Fontes: ollama.com/library/qwen3:8b • ai.google.dev/gemini-api/docs/speech-generation

Documentos e regras são parte do produto

A tecnologia permite conversar; os documentos e as regras determinam o que a conversa pode alcançar com segurança.

Identidade

Nome, apresentação, personalidade, formalidade, ritmo e expressões permitidas.

Objetivo

Atender, qualificar, agendar, cobrar, confirmar ou encaminhar.

Conhecimento

Produtos, serviços, preços, políticas, contratos, horários e perguntas frequentes.

Limites

O que não afirmar, dados sensíveis, assuntos proibidos e situações de risco.

Ações

Consultar agenda, criar registro, enviar mensagem, abrir protocolo ou transferir.

Escalonamento

Quando chamar um humano, para qual fila e o que transmitir ao atendente.

Exemplo de regra operacional

```
SE o cliente perguntar preço
→ consultar tabela oficial vigente
→ informar apenas a opção correspondente
→ nunca inventar desconto

SE solicitar condição excepcional
→ explicar que precisa de validação
→ transferir ou registrar retorno

SE demonstrar urgência ou insatisfação grave
→ parar o fluxo comercial
→ priorizar atendente humano
```

Transferência humana

Não é um detalhe opcional para produção. É a saída segura quando a IA não entende, não possui autorização, encontra risco ou recebe um pedido explícito. A transferência deve levar junto um resumo para que o cliente não precise repetir tudo.

Segurança, consentimento e LGPD

Uma chamada pode conter nome, telefone, documentos, saúde, finanças ou outras informações pessoais. Antes da produção, a operação precisa definir finalidade, retenção, acesso e exclusão.

- ☐ Informar que o atendimento é realizado ou apoiado por IA.
- ☐ Definir quando a gravação é necessária e apresentar aviso apropriado.
- ☐ Coletar somente os dados necessários ao atendimento.
- ☐ Criptografar segredos e credenciais.
- ☐ Não colocar chaves de API dentro do aplicativo distribuído.
- ☐ Controlar quem acessa gravações e transcrições.
- ☐ Definir prazo automático de exclusão.
- ☐ Mascaram documentos, cartões e informações sensíveis nos logs.
- ☐ Registrar qual documento e versão embasaram uma resposta crítica.
- ☐ Permitir intervenção e transferência para um humano.

Distribuição recomendada

COMPUTADOR DO USUÁRIO

Launcher + painel + configuração

VPS HURTZ

Gateway de chamadas + sessões + logs + regras

COMPUTADOR COM GPU ou servidor de IA

Whisper + Ollama

GOOGLE

Somente o texto necessário para sintetizar a voz

Atenção: se o Google TTS for utilizado, o texto falado será processado externamente. Isso precisa aparecer na política da operação. Para clientes com exigência de processamento integralmente local, deveremos oferecer uma voz local alternativa.

Etapas recomendadas

Etapa	Entrega	Critério de aprovação
1. Laboratório de voz	Pipecat + Whisper + Ollama + Google TTS conversando localmente.	Interrupção funciona e resposta começa com baixa latência.
2. WebCall	Página segura de chamada por link conectada à VPS.	Duas pessoas testam em redes diferentes com áudio estável.
3. Configuração	Tela para documentos, regras, voz, objetivos e transferência.	Mudanças entram sem alterar código.
4. Ações	Agenda, cadastro, protocolo, resumo e Evolution API.	A IA só executa ações autorizadas e registra resultado.
5. Telefonia/WhatsApp	Conector SIP ou prova Evolution + Waveip.	Áudio bidirecional, interrupção e transferência validados.
6. Piloto	Operação limitada com número secundário e supervisão.	Taxa de conclusão, erros e satisfação dentro das metas.

Testes que não podem ser pulados

- Cliente fala rápido, devagar, baixo e com ruído.
- Cliente interrompe a IA no início e no meio da resposta.
- Informação não existe nos documentos.
- Cliente muda completamente de assunto.
- Serviço do Google fica lento ou indisponível.
- Ollama reinicia durante uma conversa.
- Transferência não encontra atendente disponível.
- Duas chamadas acontecem simultaneamente.
- Cliente pede exclusão ou não aceita gravação.

Regra de entrega: nenhuma integração será considerada pronta apenas porque “conectou”. Precisamos medir latência, naturalidade, interrupção, recuperação de falhas e segurança.

O que está definido e o que falta validar

Item	Status	Decisão
Produto independente	Definido	Assistente Hurtz separado do Assistente de Reunião.
Orquestração	Definido	Pipecat em Python 3.12.
Transcrição	Direção definida	Faster-Whisper adaptado para streaming.
Inteligência	Benchmark	Qwen3 8B versus modelo menor de baixa latência.
Voz	Prova necessária	Gemini 3.1 Flash TTS Preview com fallback.
MVP de chamada	Recomendado	WebRTC por link.
Telefonia convencional	Pendente	Escolher tronco SIP quando o MVP estiver estável.
Chamada WhatsApp	Experimento	Validar Evolution + Wavoip + SIP com número secundário.
Regras e documentos	Conteúdo pendente	Precisam ser definidos para cada operação.
Transferência humana	Destino pendente	Definir fila, telefone e comportamento fora do horário.

Próxima decisão prática

Construir primeiro o laboratório de conversa por WebRTC. Isso prova a qualidade central do Hurtz sem depender de uma operadora ou de uma integração experimental do WhatsApp. Em paralelo, podemos auditar a VPS e testar se o Wavoip disponibiliza uma conexão SIP compatível.

Resumo final

O novo Hurtz será uma plataforma de atendimento por voz, não apenas uma integração isolada. Evolution API continuará importante para WhatsApp e automações. Pipecat coordenará a conversa. Faster-Whisper ouvirá, Ollama decidirá, Google falará e uma camada WebRTC/SIP entregará o áudio. A qualidade do produto dependerá igualmente de baixa latência, documentos corretos, regras claras, transferência humana e testes reais.

Termos para estudar

Termo	Significado simples
WebRTC	Tecnologia para voz e vídeo em tempo real pelo navegador.
SIP	Protocolo usado para iniciar e controlar chamadas de telefonia pela internet.
Tronco SIP	Serviço de operadora que conecta nosso sistema à rede de celulares e telefones.
PABX	Central que recebe, encaminha, transfere e organiza chamadas.
VAD	Detector que identifica quando existe voz no áudio.
STT	Speech-to-Text: transforma fala em texto.
LLM	Modelo de linguagem que interpreta contexto e produz a resposta.
TTS	Text-to-Speech: transforma texto em voz.
RAG	Método para localizar trechos de documentos e entregá-los ao modelo.
Barge-in	Capacidade de a pessoa interromper a IA enquanto ela fala.
Latência	Tempo entre a fala da pessoa e o início da resposta.
Webhook	Aviso automático enviado por um sistema quando um evento acontece.
Fallback	Alternativa usada quando o serviço principal falha.

Leituras técnicas recomendadas

- github.com/pipecat-ai/pipecat
- github.com/evolution-foundation/evolution-api
- docs.asterisk.org/Configuration/WebRTC/
- ai.google.dev/gemini-api/docs/speech-generation
- ollama.com/library/qwen3:8b
- wavoip.com

Documento vivo: esta estrutura deve ser atualizada após os benchmarks de voz e a validação da VPS. Tecnologias em Preview e integrações de WhatsApp podem mudar.